
DeepReasoning: destilacion cognitiva con QLoRA en GSM8K

Dimael Rivas Rodrigo Meza Leonardo Candio

Reporte final de resultados del proyecto

Resumen. Este informe documenta el sistema DeepReasoning para el proyecto final de Arquitecturas de Modelos de Lenguaje. El objetivo fue entrenar adaptadores QLoRA para inducir razonamiento estructurado en problemas GSM8K usando las etiquetas <thinking>, <reflection> y <answer>, y evaluar tanto exactitud matematica como cumplimiento de formato. Los resultados son mixtos: Qwen2.5-3B ya resolvía muchos casos y el ajuste podía imitar el estilo del teacher sin mejorar siempre la respuesta final; Qwen2.5-1.5B aprendió claramente el formato requerido, pero no superó al base en exactitud numerica flexible sobre 100 preguntas.

Conclusion principal

El fine-tuning con QLoRA enseña a producir razonamiento verbalizado y respuestas en el formato obligatorio. Sin embargo, mas razonamiento explicito no garantiza una mayor tasa de acierto. La ganancia principal observada es de alineacion de formato y estilo; la mejora de capacidad matematica depende del tamaño del modelo, la longitud de contexto y la metrica usada.

1. Enunciado y arquitectura implementada

El proyecto exigía un sistema de razonamiento profundo mediante destilación cognitiva: generación de datos sintéticos con razonamientos estructurados, ajuste fino SFT+QLoRA de un modelo pequeño y escalado en inferencia mediante Self-Consistency / Majority Voting. La implementación usa GSM8K, trazas con <thinking>, <reflection> y <answer>, entrenamiento de adaptadores LoRA sobre Qwen2.5 y evaluación con exact-match numérico, formato válido y curvas de entrenamiento.

Se reportan resultados favorables y desfavorables. Esto es importante porque la pérdida de validación, la exactitud numérica y el cumplimiento del formato responden preguntas distintas: aprender a escribir un razonamiento estructurado no implica necesariamente resolver mejor el problema.

2. Qwen2.5-3B: ablation inicial y resultados negativos


La primera fase uso Qwen2.5-3B-Instruct. Los runs iniciales de mayor learning rate degradaron la exactitud greedy del adapter frente al modelo base, aunque produjeron cierto aprendizaje del formato.

run	max	r	loss	base	adapter	formato	SC@10
len512_r16_a32	512	16	0.301	72.0%	30.0%	32.0%	53.0%
len1024_r8_a16	1024	8	0.324	72.0%	29.0%	31.0%	50.0%
len1024_r16_a32	1024	16	0.314	72.0%	26.0%	27.0%	52.0%


Lectura: max_len=512 obtuvo 30% adapter vs 72% base en los artefactos consolidados; la nota experimental del equipo registra una prueba STAR/strict con base cercano a 51% y ajustado 48%, coherente con que el ajuste no aportó una mejora clara de acierto final. Con max_len=1024, la ventana reduce truncamiento, pero los adapters iniciales caen a 26-29% greedy mientras el base permanece en 72%.

3. Graficas clave: Self-Consistency y comparaciones


3B base/1024: accuracy vs N




3B ajustado/1024: accuracy vs N



Mejor 3B: 100 GSM8K



1.5B loose numeric




4. Mejor resultado Qwen2.5-3B

Al bajar la tasa de aprendizaje a $5e-5$ y entrenar una epoca, la configuracion $\text{max_len}=1024$, $r=8$, $\alpha=16$ obtuvo 81.0% greedy exact-match frente a 72.0% del modelo base en 100 preguntas emparejadas. La diferencia fue de +9 puntos porcentuales con IC bootstrap 95% [-1, 19] puntos. El adapter produjo formato valido en 98.0% de los ejemplos y reflexion en 98.0%.

Este resultado positivo no elimina la conclusion matizada: la configuracion inicial empeoraba y la mejora aparece al controlar learning rate, epocas, longitud y presupuesto de generacion.

Confirmacion 3B: exact-match greedy




5. Cambio a Qwen2.5-1.5B


Se cambio a un modelo mas pequeno porque Qwen2.5-3B ya poseia capacidad suficiente para resolver de manera directa gran parte del dataset. Por ello, el fine-tuning con razonamientos generados por Gemini Flash no necesariamente incrementaba la capacidad real de razonamiento, sino que principalmente inducia al modelo a imitar el formato y estilo del teacher.

Confirmacion 1.5B: strict required-format answer adapter 48.0% vs base 0.0%. Loose numeric answer adapter 49.0% vs base 55.0%, diferencia -6 pp, IC [-19, 6]. Cumplimiento de formato adapter 75.0%, base 0.0%.

Strict formato requerido



Loose numeric answer



6. Screen de hiperparametros Qwen2.5-1.5B

run	r	lr	loss	strict30	loose30	format	VRAM
qwen15_len1024_r8_a16_lr5e5_e3_es	8	5e-05	0.402	63.3%	63.3%	90.0%	56.3
qwen15_len1024_r8_a16_lr2e5_e3_es	8	2e-05	0.456	56.7%	63.3%	80.0%	56.3
qwen15_len1024_r16_a32_lr5e5_e3_es	16	5e-05	0.383	53.3%	56.7%	80.0%	56.4

El screen selecciono qwen15_len1024_r8_a16_lr5e5_e3_es porque tenia la mejor exactitud strict a 30 preguntas y el mejor cumplimiento de formato. El run r=16 logro menor loss pero peor exactitud, por lo que no se eligio solo por perdida de validacion.

7. Interpretacion final

- 1) El proyecto cumple el objetivo tecnico: pipeline reproducible de destilacion cognitiva, SFT+QLoRA y Test-Time Compute sobre GSM8K.
- 2) Los adapters aprenden el formato solicitado (<thinking>, <reflection>, <answer>) de forma clara, especialmente en Qwen2.5-1.5B.
- 3) La mejora en formato no equivale automaticamente a mejora en razonamiento matematico: en 1.5B el adapter gana en strict format pero pierde ligeramente en loose numeric accuracy.
- 4) En 3B, el modelo base ya esta cerca de saturar parte del benchmark; por eso el fine-tuning puede tener poco margen y, si se configura mal, empeorar. La mejor configuracion 3B si produjo una mejora emparejada (+9 pp), pero con intervalo de confianza amplio.
- 5) La longitud de contexto debe interpretarse con cuidado: 512 tokens reduce razonamiento explicito y trunca mas ejemplos; 1024 tokens permite trazas largas, pero mas razonamiento verbalizado puede introducir ruido o sobreajuste al teacher.
- 6) La conclusion defendible es que DeepReasoning fue exitoso como alineacion de formato y estilo de razonamiento, y parcialmente exitoso como mejora de exactitud dependiendo de configuracion y metrica.