
DeepReasoning: Destilacin Cognitiva con QLoRA en GSM8K

Dimaël Rivas Rodrigo Meza Leonardo Candio

Arquitecturas de Modelos de Lenguaje

Reporte final de proyecto

Resumen

Este informe presenta el desarrollo y evaluacin de un sistema de razonamiento profundo mediante destilacin cognitiva. El sistema entrena adaptadores QLoRA para inducir respuestas estructuradas con las etiquetas <thinking>, <reflection> y <answer> en problemas GSM8K. La evaluacin diferencia dos objetivos: (i) aprender el formato de razonamiento solicitado y (ii) mejorar la exactitud matemtica final.

El resultado central es matizado. En Qwen2.5-3B, el modelo base ya tiene una capacidad alta sobre el benchmark, por lo que el fine-tuning no siempre mejora la respuesta final: con algunas configuraciones aprende a razonar ms largo pero pierde acierto. La mejor configuracin ajustada s logra 81% frente a 72% del base en 100 preguntas, aunque con intervalo de confianza amplio. En Qwen2.5-1.5B, el LoRA enseña claramente el formato requerido, pero no supera al base en exactitud numrica flexible.

Contribuciones

1. Pipeline reproducible de destilacin, SFT+QLoRA y Self-Consistency.
2. Ablacin de longitud de contexto, rango LoRA y tasa de aprendizaje.
3. Comparacin honesta entre cumplimiento de formato y exactitud matemtica.
4. Justificacin experimental del cambio de 3B a 1.5B para estresar ms el benchmark.

1. Diseo experimental

El enunciado del proyecto solicitaba emular mecanismos de razonamiento profundo en un modelo de tamao contenido mediante tres fases: generacin de un dataset sinttico con un teacher, ajuste fino supervisado con QLoRA, y escalado en inferencia con Self-Consistency o Majority Voting.

Arquitectura del sistema

Datos	GSM8K + trazas del teacher con razonamiento paso a paso.
SFT + QLoRA	Entrenamiento exclusivo de adaptadores LoRA sobre Qwen2.5.
Formato	Etiquetas obligatorias: <thinking>, <reflection>, <answer>.
Inferencia	Muestreo de N rutas y seleccin por consenso semntico / mayora.
Mtricas	Exact-match numrico, formato vlido, reflexin y Self-Consistency.

Criterio de lectura

Durante el estudio se observ que ms tokens de razonamiento no significan necesariamente mejor respuesta final. Por ello el informe separa explcitamente formato, exactitud estricta y exactitud numrica flexible. Esta separacin evita presentar como mejora de razonamiento lo que podra ser solo imitacin del estilo del teacher.

2. Ablacin principal con Qwen2.5-3B

La fase 3B es la parte principal del estudio reportada por las grficas proporcionadas. El hallazgo inicial fue negativo: varias configuraciones de fine-tuning redujeron la exactitud frente al modelo base, especialmente cuando el adapter produca razonamientos ms largos o ms rgidos.

Config.	MaxLen	r	Loss	Base	LoRA	Formato	SC@10
512_r16_a32	512	16	0.301	72%	30%	32%	53%
1024_r8_a16	1024	8	0.324	72%	29%	31%	50%
1024_r16_a32	1024	16	0.314	72%	26%	27%	52%

Observacin clave


Con `max_len=512` se registr un resultado cercano a base 51% y ajustado 48% en la prueba strict/STAR indicada por el equipo, adems del resumen consolidado donde el adapter queda por debajo del base. Con `max_len=1024`, el modelo genera razonamientos ms notorios y extensos, pero en los runs iniciales cae todava ms en las mtricas greedy. Esto sugiere que la ventana larga reduce truncamiento, pero tambin puede amplificar ruido, sobreajuste al teacher o prdida parcial de capacidades originales.

Interpretacin


Qwen2.5-3B ya resuelve directamente una fraccin importante de GSM8K. Por eso el margen de mejora real es limitado: el fine-tuning tiene ms facilidad para aprender el formato y el estilo de razonamiento que para aumentar la capacidad matemtica efectiva.

3. Gráficas de los experimentos 3B


Base 3B: Self-Consistency




LoRA 3B: Self-Consistency



Prueba strict/STAR indicada



Mejor confirmacin 3B



Las curvas de Self-Consistency muestran que aumentar N mejora la votacin, pero no elimina la brecha cuando el adapter ya parte de respuestas finales peores. La confirmacin 3B optimizada es el resultado favorable: al ajustar learning rate y poca, el adapter supera al base en la muestra de 100 preguntas.

4. Mejor configuracin 3B y lectura honesta

La mejor configuracin encontrada para Qwen2.5-3B usa max_len=1024, LoRA r=8/alpha=16, learning rate 5e-5 y una poca. En 100 preguntas fijas y emparejadas de GSM8K, el adapter obtuvo 81% de exact-match greedy frente a 72% del modelo base. La diferencia fue de +9 puntos porcentuales, con intervalo bootstrap 95% [-1, 19] puntos.

Adapter wins	Base wins	Empates
19	10	71


Adems, el adapter produjo el formato de tres etiquetas en 98% de los casos y reflexin en 98%. Este es el mejor argumento a favor del proyecto: con hiperparmetros adecuados, la destilacin no solo induce formato sino que puede mejorar la muestra evaluada.

Limitacin estadstica

El intervalo de confianza incluye un pequeo efecto negativo, por lo que no debe presentarse como prueba definitiva de mejora poblacional. La conclusin correcta es que el modelo ajustado es competitivo y probablemente mejor en esta muestra, pero se necesitaran ms subconjuntos o semillas para afirmar una mejora robusta.

5. Experimentos adicionales con Qwen2.5-1.5B

Los artefactos del repositorio incluyen una segunda fase con Qwen2.5-1.5B. Esta fase se entiende como una forma de estresar ms el benchmark: al reducir el tamao del modelo, hay menos saturacin inicial y se observa con mayor claridad qu aprende el adapter.



La confirmacin de 100 preguntas con Qwen2.5-1.5B fue muy clara: en respuesta estricta con formato requerido, el adapter logra 48% frente a 0% del base. En exactitud numrica flexible, el adapter queda en 49% frente a 55% del base, diferencia -6 pp con IC [-19, 6]. El cumplimiento de formato fue 75% para el adapter y 0% para el base.

Conclusin de la fase 1.5B

LoRA enseña el contrato de salida y produce rendimiento estricto no trivial, pero no supera al modelo base en matemtica flexible. Por tanto, el resultado apoya la hiptesis central del informe: la destilacin mejora principalmente la forma del razonamiento, no necesariamente la respuesta final.

6. Screen de hiperparmetros 1.5B

Run	r	LR	Loss	Strict30	Loose30	Formato	VRAM
r8_a16_lr5e5_e3_es	8	5e-05	0.402	63%	63%	90%	56.3
r8_a16_lr2e5_e3_es	8	2e-05	0.456	57%	63%	80%	56.3
r16_a32_lr5e5_e3_es	16	5e-05	0.383	53%	57%	80%	56.4

El screen seleccion $r=8$, $\alpha=16$ y learning rate $5e-5$ porque ofreci la mejor combinacin de exactitud estricta y formato. Un resultado importante es que la menor prdida de validacin no siempre coincide con la mejor exactitud final, por lo que se reportan ambas.

Mensaje final

DeepReasoning cumple el objetivo de construir un sistema de razonamiento estructurado con QLoRA y Test-Time Compute. El aprendizaje del formato es claro. La mejora de razonamiento efectivo es ms frgil: depende de hiperparmetros, tamao del modelo y mtrica. Por eso el reporte debe presentarse como un anlisis honesto de trade-offs, no como una victoria absoluta del fine-tuning.